Pós-graduação

Engenharia de Dados / Big Data

Aluno: Charles de Araujo Melo

Infnet - Trabalho Infraestrutura Cassandra

1. Explique, com suas palavras, as diferenças entre bases de dados SQL e NoSQL, apresentando exemplos de uso para cada uma delas.

R. O grande diferencial dos bancos de dados NoSQL é que toda a informação é agrupada e guardada no mesmo registro. Já no SQL você precisa ter o relacionamento entre várias tabelas para ter a informação, informação esta disposta no modelo entidade e relacionamento.

As bases de dados SQL utilizam uma abordagem de escala vertical, o que significa que escalam adicionando mais poder ao servidor. As bases de dados NoSQL utilizam uma abordagem de escala horizontal, o que significa que são escaladas adicionando mais servidores.

O NoSQL é mais indicado para aqueles sistemas que tenham necessidades maiores de armazenamento e desempenho com dados não estruturados. Já o SQL é indicado quando necessitamos de maior consistência.

2. Escolha uma base de dados pública brasileira, que será o alvo para condução de seu Projeto de Disciplina. Esta base será carregada para uma infraestrutura Cassandra, para dar suporte à geração de um processo de análise de dados.

R. Base de dados escolida : food-preference https://www.kaggle.com/datasets/naufaal98/food-preference

- **3.** Defina pelo menos uma pergunta de negócio que será o objetivo de seu processo de análise a ser desenvolvido a partir dos dados armazenados na infraestrutura Cassandra.
- **R.** Todos Clientes com idade maior que 30 anos e que comeram sobremesa.
- R. Média da idade de todos os clientes do gênero masculino e que não comeram sobremesa.

- **1.1** Apresente um planejamento básico da infraestrutura necessária para comportar os dados que deseja importar.
- **1.2** Apresente a descrição das configurações feitas em um ambiente computacional para receber a infraestrutura Cassandra. Ao final deste passo, a máquina que hospedará o ambiente deverá estar pronta para receber o conjunto de dados escolhido para o trabalho.
- **1.3** Faça a carga de dados para o ambiente configurado e execute todas as atividades necessárias na base para que a infraestrutura fique pronta para a execução de operações com os dados. Apresente uma comprovação de que a carga de dados tenha sido corretamente executada.

Usarei o Docker para criar um container com a imagem do cassandra.

Instalação e configuração do Cassandra (via container Docker):

https://www.docker.com/products/docker-desktop/

Baixa a imagem do Cassandra no Docker Hub para a máquina local

1.1 Baixar a imagem:

docker pull cassandra

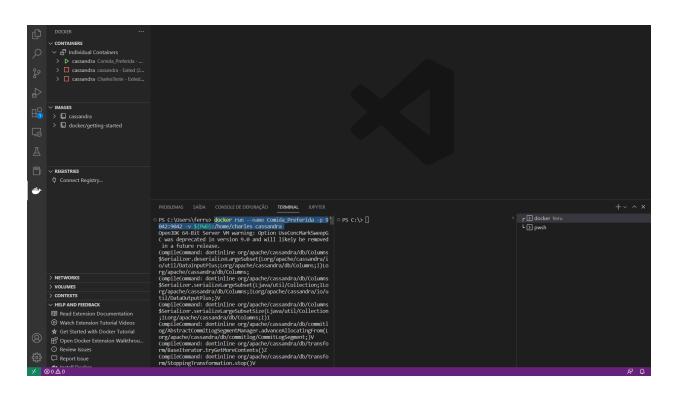
1.2 Visualizar as imagens existentes na máquina

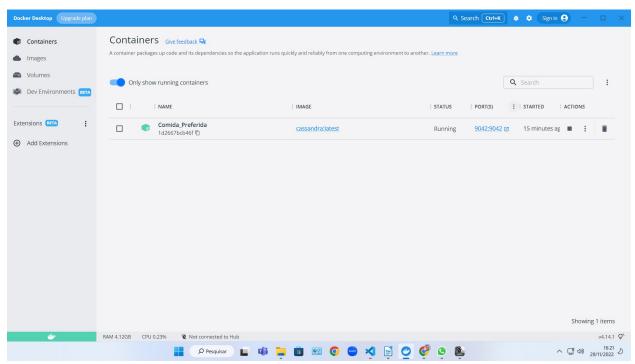
docker image Is

Utilizando o terminal do Visual Studio Code para criar meu container com espelhamento em meu diretório local para por meus arquivos para serem enxergados dentro do container.

Utilizei o seguinte comando:

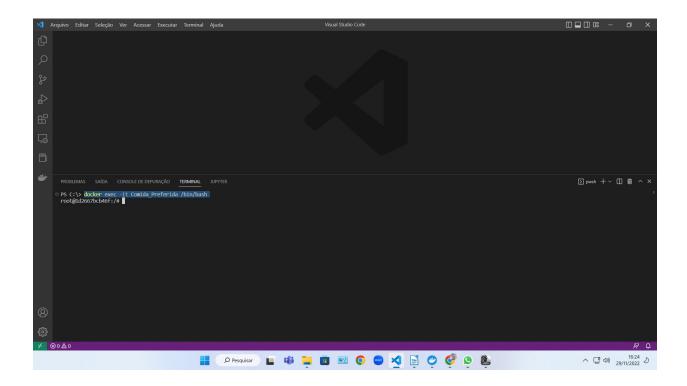
docker run --name Comida Preferida -p 9042:9042 -v \${PWD}:/home/charles cassandra





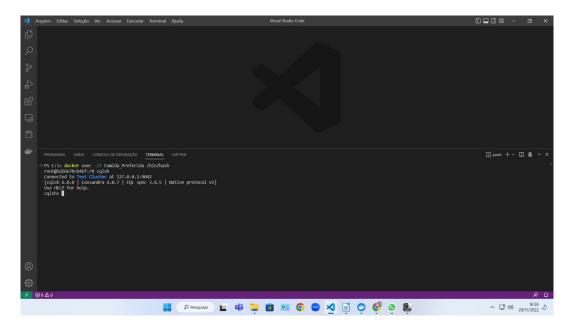
Iniciando meu container atráves de um terminal do (Visual Studio Code).

docker exec -it Comida_Preferida /bin/bash



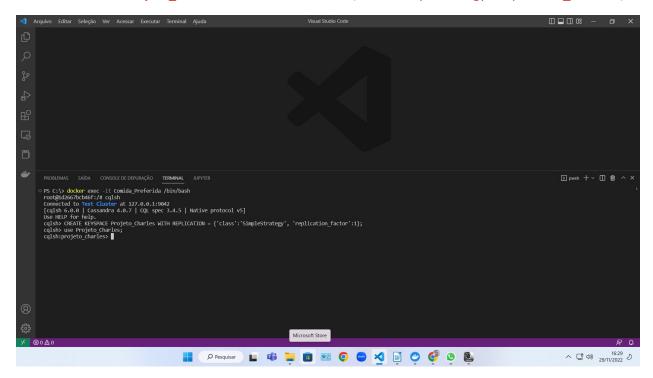
Linguagem de consulta Cassandra(CQL) é a principal linguagem para se comunicar com o Apache Cassandra.

Comando: CQLSH

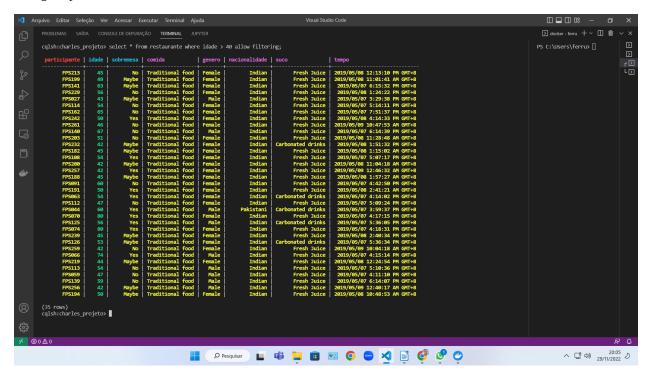


Criando a Keyspace e acessando:

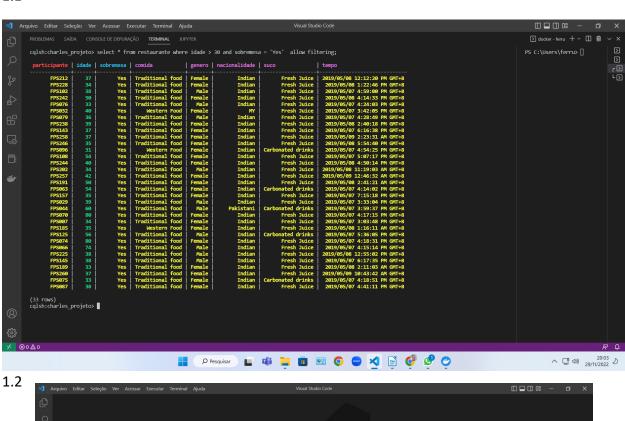
CREATE KEYSPACE Projeto_Charles WITH REPLICATION = {'class':'SimpleStrategy', 'replication_factor':1};

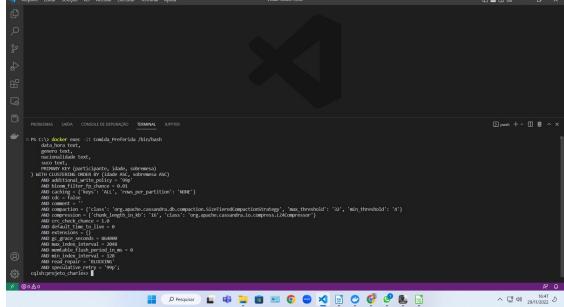


1.4 Apresente o código e uma comprovação de sucesso de execução de uma consulta de leitura na base de dados carregada para a infraestrutura Cassandra.

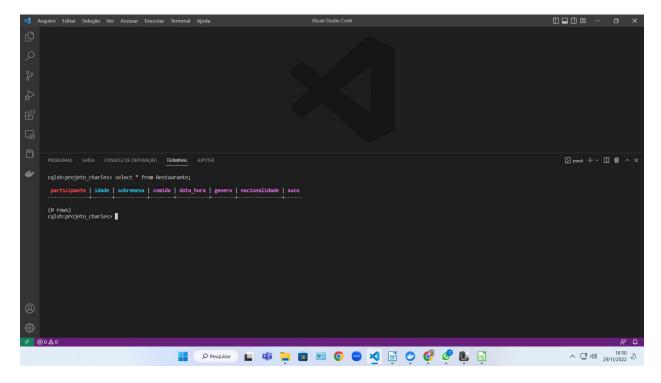


- **1.5** Utilizando linguagem Python, extraia o conjunto de informações necessário para dar prosseguimento ao processo de resposta à(s) pergunta(s) de negócio estabelecida(s) na questão 3. Apresente o código criado para a extração e uma comprovação de sucesso da operação.
- **1.6** Execute quaisquer operações de manipulação, ajuste e criação de variáveis necessárias para dar apoio à resposta do problema de negócio em estudo. Apresente códigos em Python de pelo menos uma operação de manipulação de dados e uma operação de criação de novas variáveis.
- **R.** 1.1 Todos clientes com idade maior que 30 anos e que comeram sobremesa.
- **R.** 1.2 Média da idade de todos os clientes do gênero masculino e que não comeram sobremesa.
- 1.1

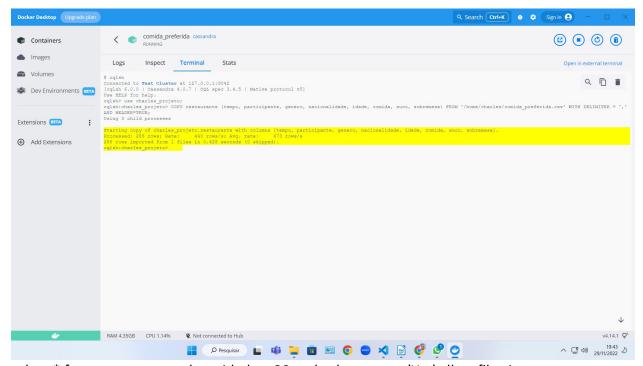




Select na tabela criada:



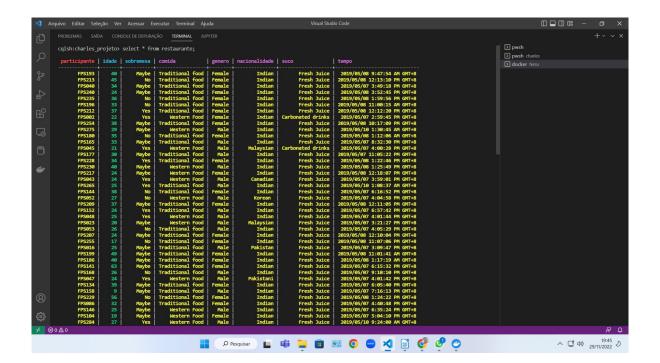
Importando os dados do arquivo comida_preferida.csv para minha tabela restaurante:



select * from restaurante where idade > 30 and sobremesa = 'Yes' allow filtering;

1.6 Exporte a base tratada final para formato CSV. Apresente o código em Python que demonstre a execução desta operação.

COPY restaurante (tempo, participante, genero, nacionalidade, idade, comida, suco, sobremesa) FROM '/home/charles/comida preferida.csv' WITH DELIMITER = ',' AND HEADER=TRUE;



- **1.7** Crie pelo menos uma visualização de dados que utilize um gráfico de barras e dê suporte à resposta para a(s) pergunta(s) de negócio estabelecida(s) na questão 3. Apresente a visualização gerada e como ela ajuda a responder a solução do problema proposto.
- **1.8** Crie pelo menos uma visualização de dados que utilize um gráfico de dispersão e dê suporte à resposta para a(s) pergunta(s) de negócio estabelecida(s) na questão 3. Apresente a visualização gerada e como ela ajuda a responder a solução do problema proposto.

Processando os dados e plotando alguns gráficos

Nesta etapa, vamos nos conectar as tabelas do Cassandra via Python e faremos alguns processando nos dados com PySpark para respondermos as perguntas iniciais sobre os dados. Também plotaremos alguns gráficos para deixar a análise um pouco mais visual.

Instalando bibliotecas não existentes na máquina

!pip install findspark

Collecting findspark Downloading findspark-2.0.1-py2.py3-none-any.whl (4.4 kB) Installing collected packages: findspark Successfully installed findspark-2.0.1

Importando as bibliotecas

```
from pyspark import SparkContext, SparkConf
from pyspark.sql import *

from pyspark.sql.functions import *

import os

import sys

import findspark

import numpy

import pandas as pd

import matplotlib.pyplot as plt
```

Configurando o SparkConf

```
findspark.init()

os.environ['PYSPARK_SUBMIT_ARGS'] = '--packages com.datastax.spark:spark-cassandra'

conf = SparkConf()

conf.set('spark.cassandra.auth.username', 'cassandra')

conf.set('spark.cassandra.auth.password', 'cassandra')

conf.set('spark.cassandra.connection.host', 'localhost')

conf.set('spark.cassandra.connection.local_dc', 'dc1')
```

Criando o objeto SparkContext, através do objeto SparkConf configurado (conf)

sc = SparkContext().getOrCreate(conf) # Criando um objeto SQLContext do Spark também, que utiliza o objeto SparkContext sqlContext = SQLContext(sc)

```
import matplotlib.pyplot as plt
```

```
x = [42, 46, 47, 51, 54, 56, 59, 60, 65, 67]
y1 = [1, 1, 2, 1, 1, 2, 2, 1, 1, 1]
y2 = [1, 1, 2, 1, 1, 2, 2, 1, 1, 1]
plt.plot(x, y1, label="line L")
plt.plot(x, y2, label="line H")
plt.plot()

plt.xlabel("x axis")
plt.ylabel("y axis")
plt.title("Line Graph Example")
plt.legend()
plt.show()
```

